

1. Место и сроки проведения практики:Наименование организации: МАИ, кафедра 806Сроки проведения практики 10.02.2025 - 11.05.2025дата начала практики: 10.02.2025дата окончания практики: 11.05.2025**2. Инструктаж по технике безопасности:**

_____/ Булакина М.Б. / 10 февраля 2025 г.
подпись проводившего *расшифровка подписи* *дата проведения*

3. Индивидуальное задание обучающегося:Разработка приложения транскрибации аудиопотока**4. План выполнения индивидуального задания обучающегося:**

№ п/п	Место проведения	Тема	Период выполнения
1	Каф. 806	Инструктаж	10.02.2025
2	Каф. 806	Получение индивидуального задания	10.02.2025
3	Каф. 806	Подбор литературы по теоретической части практики	11.02.2025-23.02.2025
4	Каф. 806	Разработка приложения транскрибации аудиопотока	23.02.2025-30.04.2025
5	Каф. 806	Оформление отчета. Подведение итогов.	01.05.2025-11.05.2025

Утверждаю

_____/ Булакина М.Б. / 10 февраля 2025г.
подпись руководителя от МАИ *расшифровка подписи* *дата утверждения**

_____/ Судаков В.А. / 10 февраля 2025г.
подпись руководителя от организации/предприятия *расшифровка подписи* *дата утверждения**

Ознакомлен

_____/ Александрова С.С. / 10 февраля 2025г.
подпись обучающегося *расшифровка подписи* *дата ознакомления**

*Дата утверждения и ознакомления – дата начала практики

5. Отзыв руководителя практики от организации/предприятия:

[illegible]

_____ / _____ / 10 мая 2025г.
подпись руководителя от расшифровка подписи дата
организации/предприятия

6. Отчет обучающего по практике:

В ходе работы был разработан проект, ориентированный на решение актуальной задачи – создание эффективной и безопасной системы автоматического распознавания речи с мультимедийных источников (аудио- и видеозаписей), обладающей возможностью локальной обработки данных. Актуальность обусловлена растущими требованиями к защите конфиденциальной информации и потребностью в автономных системах, способных функционировать без постоянного подключения к облачным сервисам. Это особенно важно в корпоративной, образовательной и правовой среде, где обработка записей заседаний, интервью, лекций и допросов требует строгого соблюдения норм информационной безопасности.

Цель заключалась в построении архитектурно и функционально целостной системы, которая позволяла бы пользователю загружать записи, выбирать режим транскрибирования и получать разметку по спикерам в автоматическом режиме. При этом распознавание речи, определение границ речевых фрагментов и выделение говорящих должна была выполняться локально. Такой подход исключает риски утечки данных и уменьшает операционные расходы, связанные с оплатой сторонних сервисов.

Для достижения поставленной цели были сформулированы конкретные задачи:


- проектирование модульной архитектуры, охватывающей весь цикл обработки: от загрузки данных до получения результатов транскрипции;
- реализация пользовательского интерфейса, обеспечивающего простоту взаимодействия с системой;
- интеграция двух типов моделей распознавания: «быстрой» и «точной», с возможностью их выбора в зависимости от требований к скорости и точности;
- поддержка обработки записей с различным числом участников, включая автоматическое выделение спикеров и разметку;
- внедрение механизмов оценки качества транскрибации с использованием стандартных метрик (WER, Accuracy, Speed Factor);
- обеспечение соответствия требованиям по защите персональных данных за счет полной локализации всех вычислительных процессов.

Система была построена по модульному принципу, обеспечивающему масштабируемость и независимость компонентов. Вся структура была развернута внутри Docker-сети.

Основные модули:

- **Frontend** – интерфейс для пользователя, через который выполняется загрузка файлов и получение результатов. Все действия инициируются HTTP-запросами к backend.
- **Backend** – логика обработки, прием запросов, маршрутизация задач, хранение метаданных. Обеспечивает связь между интерфейсом, обработчиком и базой данных.
- **Processing** – сервис, реализующий транскрипцию, шумоподавление, сегментацию речи и диаризацию. Поддерживает выбор модели обработки.
- **Database** – локальное хранилище данных с возможностью сохранять статус задач, текст транскрипции, тайминги и сведения о моделях.

Взаимодействие между компонентами реализовано через REST API и SQL-запросы по сервисным именам в рамках одной виртуальной сети. Такой подход гарантировал безопасность, отказоустойчивость и удобство мониторинга (рисунок 1, 2).



Frontend <--> Backend
по сервисному имени
(processing:5000) с
использованием HTTP-
запросов (REST API).

Backend <--> Processing
по сервисному имени
(processing:5000) с использованием
HTTP-запросов (REST API).

Backend <--> Database
по сервисному имени
(db:5432) с использованием
SQL-запросов.

Рисунок 1 – Архитектура приложения




Рисунок 2 – Модули приложения

В проекте были реализованы две модели транскрибирования:

- Быстрая модель (FFS) — ориентирована на одnogолосые записи, использует Whisper Large v3 Turbo. Позволяет обрабатывать большие объемы данных за короткое время, но с меньшей точностью.
- Точная модель (FFM) — использует pyannote-audio от Meta, поддерживает многоспикерные записи, включает диаризацию и более точное распознавание.

Предобработка включала извлечение звуковой дорожки из видео и сегментацию аудио с помощью алгоритма VAD. Для распознавания речи применялась библиотека VOSK, а для диаризации — pyannote-audio.

Для подготовки аудио и нарезки использовалось ПО Audacity. Оно поддерживает популярные форматы (WAV, MP3, OGG, FLAC) и позволяет легко выделять фрагменты по таймкодам.

Модель обрабатывала аудио в пакетах — записи разбивались на отрезки по 2 минуты и склеивались в блоки по 8 минут (примерно 1000 слов). Это позволило проводить тестирование в условиях, близких к реальным, с равномерной нагрузкой.

Разработка завершилась формированием работоспособной локальной системы для транскрибирования аудиозаписей с несколькими спикерами. Архитектура реализована через

набор взаимодействующих модулей, включающих пользовательский интерфейс, обработку аудио, распознавание речи, диаризацию и локальное хранилище.

Система поддерживает выбор между режимами быстрой и точной обработки, показывает стабильные результаты по скорости и качеству. Проведенное тестирование подтвердило соответствие целевым метрикам и корректную работу всех компонентов.

Проект готов к применению в задачах, где требуется автономная и конфиденциальная обработка речевой информации.

В режиме быстрой транскрибации применялась модель на базе библиотеки VOSK — легковесного и эффективного инструмента для локального распознавания речи. Она подходит для задач, где критична скорость обработки и допустим умеренный уровень точности. Модель позволяет работать без подключения к интернету, имеет низкие системные требования и поддерживает русский язык. Распознавание проводится без встроенной диаризации, поэтому она дополняется внешними средствами в случае необходимости.

В проекте модель Whisper применялась для реализации точной транскрибации аудиозаписей. Это нейросетевая система, обученная на масштабном корпусе многоязычных аудиоданных. В качестве основной версии использовалась Whisper Large v3, которая запускалась локально и обеспечивала высокое качество распознавания речи, включая поддержание пунктуации, работу с разными акцентами и устойчивость к фоновому шуму. Благодаря этому модель позволяла получать детализированные и близкие к исходному аудиоматериалу тексты, пригодные для дальнейшей разметки и анализа.

Сравнительные результаты анализа работы моделей приведены в таблице 1.

Таблица 1 - Сравнительная таблица моделей транскрибации

Параметр	Whisper (точная модель)	VOSK (быстрая модель)
Назначение	Точная транскрипция	Быстрая транскрипция
Модуль в системе	FFM (Fast Multi-speaker)	FFS (Fast Single-speaker)
Библиотека / реализация	Whisper Large v3	VOSK (на базе Kaldi)
Режим работы	Локальный, офлайн	Локальный, офлайн
Поддержка русского языка	Полная, с учетом акцентов и пунктуации	Есть, базовая лексика
Тип результата	Текст с пунктуацией и таймкодами	Текст с таймкодами
Диаризация	Внешняя (pyannote)	Не встроена, требуется внешняя реализация
Скорость обработки	15–18 минут на 1000 слов	6–8 минут на 1000 слов
Точность (WER)	До 0.3%	До 0.7%
Особенности	Высокая точность, устойчива к шуму	Минимальные требования, высокая скорость

В проекте использовались стандартные метрики качества распознавания речи — WER, Accurasy и Speed Factor, обеспечивающие оценку точности и скорости обработки аудиозаписей (таблицы 2,3).

Таблица 2 - Используемые метрики

Метрика	Назначение	Формула / принцип расчета
WER (Word Error Rate)	Оценка количества ошибок в тексте транскрипции	$(S + D + I) / N$, где S – замены, D – пропуски, I – вставки, N – общее число слов
Accuracy	Доля корректно распознанных слов	$(\text{Правильно распознанные слова}) / (\text{Общее число слов})$
SF (Speed Factor)	Соотношение времени распознавания и длины записи	$T_{\text{расп}} / T_{\text{аудио}}$

Таблица 3 - Целевые значения метрик

Модель	WER (макс.)	Accuracy (мин.)	Время обработки (макс.)	Объем теста
Быстрая (FFS)	≤ 0.007	$\geq 99.3\%$	≤ 10 минут на 1000 слов	1000 слов
Точная (FFM)	≤ 0.003	$\geq 99.7\%$	≤ 20 минут на 1000 слов	1000 слов

Для отслеживания состояния системы и оценки ее производительности были внедрены средства внутреннего мониторинга, охватывающие все ключевые компоненты.

Frontend: контролировались количество и тип HTTP-запросов (коды 200, 400, 500), время отклика, а также загрузка статических ресурсов (CSS, JS). Это позволяло оперативно выявлять сбои пользовательского интерфейса и проблемы с доступностью.

Backend: отслеживалось количество входящих API-запросов, среднее время их обработки и наличие ошибок исполнения. Эти данные использовались для оценки нагрузки и выявления узких мест в логике приложения.

Processing: учитывались количество активных задач, время их выполнения в зависимости от выбранной модели (FFS или FFM), а также использование процессора и памяти. Это обеспечивало контроль за эффективностью обработки и загрузкой вычислительных ресурсов.

Database: собирались сведения о числе активных соединений, количестве и скорости выполнения SQL-запросов, что позволяло оценивать стабильность работы хранилища данных.

Docker: фиксировались данные о загрузке CPU, памяти и сети для каждого контейнера, а также их текущее состояние (работает или остановлен).

Система мониторинга обеспечивала прозрачность всех процессов и позволяла своевременно реагировать на возникающие проблемы.

Система тестировалась на 10 аудиозаписях дикторской речи длительностью 1 час. Каждая запись разбивалась на фрагменты по 2 минуты и объединялась в блоки по 8 минут (примерно 1000 слов). Использовались обе модели с фиксацией времени обработки и качества распознавания. Предварительная обработка аудио выполнялась в Audacity, применялась нормализация и шумоподавление. Фактические значения метрик приведены в таблице 4.

Таблица 4 - Фактические значения метрик

Модель	Среднее время на 1000 слов	WER (%)	Ошибок на 1000 слов
Быстрая (FFS)	6–8 мин	≤ 0.7	≤ 7
Точная (FFM)	15–18 мин	≤ 0.3	≤ 3

В результате была сформирована работоспособная локальная система (MVP) для транскрибирования аудиозаписей с несколькими спикерами. Архитектура реализована через

набор взаимодействующих модулей, включающих пользовательский интерфейс, обработку аудио, распознавание речи, диаризацию и локальное хранилище.

Система поддерживает выбор между режимами быстрой и точной обработки, показывает стабильные результаты по скорости и качеству. Проведенное тестирование подтвердило соответствие целевым метрикам и корректную работу всех компонентов.

Проект готов к применению в задачах, где требуется автономная и конфиденциальная обработка речевой информации. Таким образом все задачи выполнены, а цель достигнута

подпись обучающегося

/ Александрова С.С. /
расшифровка подписи

10 мая 2025г.
дата